ANALISIS KOMPARATIF ARSITEKTUR TRANSFORMER: EVALUASI MENDALAM TERHADAP PEMAHAMAN KONTEKSTUAL BERT DAN KEMAMPUAN GENERATIF MULTIMODAL GPT-4

BAB I PENDAHULUAN

1.1 Latar Belakang

Lanskap teknologi global telah mengalami pergeseran paradigma yang fundamental sejak dimulainya milenium baru, dengan kecerdasan buatan atau *Artificial Intelligence* (AI) bertindak sebagai katalis utama dalam revolusi industri keempat. Pada tingkat yang paling mendasar, AI merupakan entitas cerdas ilmiah yang diciptakan oleh manusia melalui algoritma dan pemrosesan data masif, yang memungkinkan mesin untuk berpikir, belajar, dan mengambil keputusan secara mandiri.[1] Sejarah AI tidaklah linier; bidang ini telah melalui siklus optimisme yang tinggi, diikuti oleh periode kekecewaan dan pemotongan pendanaan yang dikenal sebagai "AI Winter," sebelum akhirnya mencapai kematangan teknis pada dekade 2020-an melalui ketersediaan data web yang masif dan kemajuan perangkat keras GPU.[2]

Dalam spektrum AI, Pemrosesan Bahasa Alami atau *Natural Language Processing* (NLP) menempati posisi yang sangat krusial. NLP bertujuan untuk menjembatani kesenjangan antara kompleksitas linguistik manusia dengan keterbatasan sistem biner komputer, memungkinkan mesin untuk memahami, menafsirkan, dan menghasilkan bahasa alami secara bermakna.[4] Evolusi NLP dimulai dari sistem berbasis aturan yang sangat kaku pada tahun 1960-an, seperti program ELIZA yang mensimulasikan percakapan melalui pencocokan kata kunci, hingga transisi ke model statistik n-gram pada tahun 1990-an.[3] Namun, lompatan kuantum yang sesungguhnya terjadi dengan diperkenalkannya arsitektur Transformer pada tahun 2017, yang secara efektif menggantikan model *Recurrent Neural Networks* (RNN) dan *Long Short-Term Memory* (LSTM) yang lambat dalam memproses urutan teks panjang.[8]

Munculnya dua model bahasa besar atau *Large Language Models* (LLM) yang dominan, yakni BERT (*Bidirectional Encoder Representations from Transformers*) dan GPT-4 (*Generative Pre-trained Transformer 4*), telah mengubah secara total cara manusia berinteraksi dengan informasi digital.[11] BERT, yang diperkenalkan oleh peneliti Google pada tahun 2018, membawa revolusi dalam pemahaman konteks bahasa secara bidireksional, menjadikannya standar emas untuk tugas-tugas pencarian informasi dan klasifikasi teks.[14] Di sisi lain, GPT-4, yang dikembangkan oleh OpenAI, merepresentasikan puncak dari model generatif autoregresif yang

tidak hanya mampu menulis teks berkualitas manusia, tetapi juga memahami input visual secara multimodal.[16] Pemahaman mendalam tentang perbandingan kedua model ini menjadi sangat vital bagi akademisi dan praktisi teknologi untuk menentukan alat yang paling efisien, aman, dan tepat guna dalam menyelesaikan berbagai tantangan modern, mulai dari analisis sentimen hingga penalaran hukum yang kompleks.[13]

1.2 Rumusan Masalah

Analisis mendalam ini dirancang untuk menjawab serangkaian permasalahan teknis dan konseptual yang berkaitan dengan model bahasa modern, dengan rumusan masalah sebagai berikut:

1. Bagaimana definisi operasional serta karakteristik fundamental dari model GPT-4 dan BERT dalam konteks ekosistem kecerdasan buatan saat ini? [12]
2. Bagaimana mekanisme kerja teknis dari kedua model tersebut, khususnya dalam pemanfaatan komponen encoder-decoder pada arsitektur Transformer dan implementasi mekanisme atensi mandiri (*self-attention*)? [20]
3. Apa saja perbedaan signifikan, keunggulan komparatif, serta batasan-batasan etis dan teknis yang dimiliki oleh masing-masing model dalam menangani tugas-tugas NLP di dunia nyata? [11]

1.3 Tujuan Penelitian

Laporan ini disusun dengan tujuan utama untuk memberikan tinjauan sistematis dan komprehensif mengenai perbandingan performa serta efisiensi antara GPT-4 dan BERT. Secara spesifik, penelitian ini bertujuan untuk mengevaluasi efektivitas arsitektur *decoder-only* pada GPT-4 dalam tugas-tugas generatif dan kreatif dibandingkan dengan arsitektur *encoder-only* pada BERT untuk tugas-tugas pemahaman mendalam dan klasifikasi.[12] Lebih jauh lagi, analisis ini bertujuan untuk memetakan skenario penggunaan yang paling optimal bagi masing-masing model berdasarkan kebutuhan skalabilitas, biaya komputasi, dan akurasi kontekstual, sehingga pembaca dapat membuat keputusan berbasis data dalam pemilihan teknologi AI.[19]

1.4 Manfaat Penelitian

Penelitian ini diharapkan dapat memberikan manfaat yang luas, baik dari perspektif akademis maupun praktis:

- **Manfaat Akademis**: Memberikan kontribusi teoritis pada literatur ilmu komputer mengenai evolusi model bahasa besar dan implementasi mekanisme *self-attention*.[28] Selain itu, laporan ini memperdalam pemahaman mengenai tantangan etis seperti halusinasi AI, bias algoritma, dan integritas akademik di era AI generatif.[30]
- **Manfaat Praktis**: Menjadi panduan bagi pengembang perangkat lunak, peneliti AI, dan pemimpin bisnis dalam memilih arsitektur model yang tepat untuk aplikasi industri tertentu, seperti chatbot layanan pelanggan, sistem pencarian medis, atau alat analisis opini publik.[12] Dengan memahami kelemahan masing-masing model, pemangku

kepentingan dapat mengimplementasikan strategi mitigasi risiko yang lebih efektif.[16]

BAB II LANDASAN TEORI

2.1 Pengertian Artificial Intelligence

Kecerdasan Buatan atau *Artificial Intelligence* (AI) merupakan bidang ilmu komputer yang bertujuan untuk menciptakan sistem yang mampu mensimulasikan kemampuan kognitif manusia dalam memecahkan masalah.[2] John McCarthy, yang secara luas dianggap sebagai bapak AI, mendefinisikan AI pada tahun 1956 sebagai sains dan rekayasa untuk membuat mesin cerdas, terutama melalui program komputer cerdas.[35] Penting untuk dicatat bahwa McCarthy menekankan bahwa AI tidak perlu membatasi dirinya pada metode yang secara biologis dapat diamati pada manusia, yang berarti AI dapat menggunakan logika matematika dan statistik yang melampaui proses berpikir manusia.[35]

Secara konseptual, evolusi AI dapat dipetakan melalui empat tujuan utama yang dirumuskan oleh Stuart Russell dan Peter Norvig dalam teks standar mereka, *Artificial Intelligence: A Modern Approach* [35]:

Kategori Pendekatan	**Deskripsi Fokus**
Sistem yang berpikir seperti manusia	Pemodelan kognitif dan pengambilan keputusan berdasarkan proses internal manusia.
Sistem yang bertindak seperti manusia	Fokus pada output yang tidak dapat dibedakan dari tindakan manusia (Turing Test).
Sistem yang berpikir secara rasional	Penggunaan hukum logika untuk menarik kesimpulan yang benar.
Sistem yang bertindak secara rasional	Penciptaan agen cerdas yang mengambil tindakan terbaik untuk mencapai tujuan.

Prinsip "agen cerdas" menjadi tema pemersatu dalam AI modern, di mana sebuah sistem

menerima persepsi dari lingkungannya melalui sensor dan melakukan tindakan melalui aktuator untuk memaksimalkan peluang keberhasilan.[37] Di era saat ini, AI telah bertransformasi menjadi disiplin ilmu yang menggabungkan statistika, kalkulus, dan jaringan saraf tiruan untuk memproses dataset besar dalam tugas-tugas prediksi dan klasifikasi.[1]

2.2 Pengertian Natural Language Processing (NLP)

Natural Language Processing (NLP) adalah cabang AI yang berfokus pada interaksi antara komputer dan bahasa manusia.[2] NLP mengintegrasikan linguistik komputasi dengan model pembelajaran mendalam untuk memproses data tekstual atau audio dalam skala besar.[4] Kegunaan utama NLP mencakup berbagai aspek kehidupan digital, mulai dari mesin penerjemah otomatis, analisis sentimen di media sosial, hingga asisten virtual seperti Siri dan Alexa.[2]

Sejarah perkembangan NLP menunjukkan transisi dari manipulasi simbolik menuju pembelajaran representasi vektor.[6] Fase-fase utama perkembangannya meliputi:

1. **Era Simbolik (1950-an - 1990-an)**: Penggunaan aturan tata bahasa yang ditulis secara manual. Contoh klasiknya adalah ELIZA (1966), yang menggunakan skrip pencocokan pola untuk mensimulasikan terapis Rogerian.[3]
2. **Era Statistik (1990-an - 2010-an)**: Penggunaan model probabilitas seperti Hidden Markov Models (HMM) dan n-grams untuk memprediksi kata berdasarkan frekuensi kemunculannya dalam korpus teks besar.[6]
3. **Era Neural & Word Embeddings (2013 - 2017)**: Munculnya Word2Vec oleh peneliti Google, yang memetakan kata ke dalam ruang vektor sehingga kata-kata dengan makna serupa memiliki kedekatan geometris.[6]
4. **Era Transformer (2017 - Sekarang)**: Dominasi model bahasa besar yang menggunakan mekanisme atensi mandiri untuk memahami konteks global dari sebuah kalimat secara simultan.[4]

2.3 Arsitektur Transformer

Arsitektur Transformer, yang diperkenalkan dalam makalah seminal "Attention is All You Need" (2017), merupakan fondasi teknis dari GPT-4 dan BERT.[8] Berbeda dengan arsitektur sebelumnya (RNN) yang memproses kata secara berurutan satu per satu, Transformer memproses seluruh urutan kata secara paralel, yang secara dramatis meningkatkan efisiensi pelatihan pada dataset masif.[9]

Komponen utama arsitektur Transformer meliputi:

2.3.1 Mekanisme Atensi Mandiri (Self-Attention)

Mekanisme ini memungkinkan model untuk secara dinamis memberikan bobot penting pada kata-kata yang berbeda dalam sebuah kalimat saat memproses satu kata tertentu.[20] Sebagai contoh, dalam kalimat "Bank itu memberikan pinjaman karena memiliki banyak dana," kata "ia"

(jika ada) akan diarahkan oleh mekanisme atensi untuk merujuk pada "Bank" bukan "dana".[21] Secara teknis, setiap kata input diubah menjadi tiga representasi vektor:

- **Query (Q)**: Apa yang dicari oleh token saat ini.
- **Key (K)**: Informasi apa yang ditawarkan oleh token lain.
- **Value (V)**: Isi informasi aktual dari token tersebut.[20]

Skor atensi dihitung melalui operasi *dot-product* antara Q dan K, yang kemudian dinormalisasi menggunakan fungsi *softmax* untuk mendapatkan bobot akhir terhadap vektor V.[20] Persamaan matematisnya adalah:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

Di mana d_k adalah dimensi dari vektor kunci yang digunakan untuk stabilitas gradien.[20]

2.3.2 Multi-Head Attention

Transformer menggunakan beberapa "kepala" atensi yang bekerja secara paralel.[20] Setiap kepala mempelajari hubungan yang berbeda antara token, seperti hubungan sintaksis (tata bahasa) atau hubungan semantik (makna), yang kemudian digabungkan untuk membentuk representasi akhir yang kaya akan informasi.[4]

2.3.3 Struktur Encoder dan Decoder

Arsitektur asli Transformer terdiri dari tumpukan *encoder* dan *decoder* [8]:

- **Encoder**: Bertugas memetakan urutan input menjadi representasi vektor abstrak. Encoder melihat konteks secara bidireksional (seluruh kalimat sekaligus).[23]
- **Decoder**: Bertugas menghasilkan urutan output satu per satu. Decoder menggunakan *masked self-attention* untuk memastikan bahwa prediksi untuk posisi tertentu hanya bergantung pada kata-kata yang sudah dihasilkan sebelumnya, bukan kata di masa depan.[9]

2.4 Penjelasan Model GPT-4

2.4.1 Pengertian GPT-4

GPT-4 (*Generative Pre-trained Transformer 4*) adalah sistem AI multimodal paling canggih yang dikembangkan oleh OpenAI.[16] Sebagai model generatif, GPT-4 dirancang untuk menghasilkan teks alami yang sulit dibedakan dari tulisan manusia berdasarkan instruksi atau *prompt* yang diberikan.[39] Berbeda dengan pendahulunya, GPT-4 mampu menerima input

berupa teks dan gambar, memungkinkannya untuk melakukan analisis visual yang kompleks.[16]

2.4.2 Cara Kerja GPT-4

Mekanisme kerja GPT-4 melibatkan dua tahap utama:

1. **Pre-training**: Model dilatih pada dataset raksasa dari internet untuk memprediksi token berikutnya dalam sebuah urutan. Dalam tahap ini, model mempelajari pola bahasa, fakta dunia, dan kemampuan penalaran dasar secara mandiri.[4]
2. **Alignment (Fine-tuning)**: Setelah pra-pelatihan, model disempurnakan menggunakan teknik *Reinforcement Learning from Human Feedback* (RLHF).[17] Manusia memberikan umpan balik pada berbagai jawaban model, membantu AI untuk menjadi lebih patuh pada instruksi, lebih aman, dan meminimalkan bias.[16]

2.4.3 Arsitektur GPT

GPT-4 menggunakan arsitektur *decoder-only*.[17] Ini berarti model ini hanya terdiri dari tumpukan lapisan decoder Transformer tanpa komponen encoder terpisah.[23] Sifatnya yang autoregresif berarti model memproses informasi secara searah (kiri-ke-kanan), di mana setiap kata baru diprediksi berdasarkan sejarah kata-kata sebelumnya.[11] Skala model ini sangat masif, dengan estimasi mencapai 1,8 triliun parameter, menjadikannya jauh lebih besar daripada BERT.[4]

2.4.4 Fungsi dan Penggunaan GPT-4

Fungsi utama GPT-4 adalah sebagai "asisten kognitif" yang serbaguna.[17] Kegunaannya meliputi:

- **Generasi Konten**: Menulis esai, artikel, puisi, dan skenario kreatif dengan koherensi tinggi.[39]
- **Pemrograman**: Menghasilkan, men-debug, dan menjelaskan kode dalam berbagai bahasa pemrograman.[16]
- **Penalaran Kompleks**: Menyelesaikan masalah matematika tingkat lanjut, analisis hukum, dan ringkasan dokumen teknis yang panjang.[16]

2.4.5 Contoh Penggunaan GPT-4 dalam Dunia Nyata

Dalam praktik industri, GPT-4 diintegrasikan ke dalam Microsoft Copilot untuk membantu produktivitas kantor dan dalam ChatGPT Plus untuk interaksi pengguna umum.[17] Aplikasi pendidikan menggunakan GPT-4 untuk memberikan bimbingan belajar yang dipersonalisasi, di mana model dapat menjelaskan konsep sulit seperti kalkulus atau kimia dalam bahasa yang sederhana.[40] Selain itu, GPT-4 digunakan oleh firma hukum untuk meninjau ribuan halaman dokumen legal dalam waktu singkat.[18]

2.5 Penjelasan Model BERT

2.5.1 Pengertian BERT

BERT (*Bidirectional Encoder Representations from Transformers*) adalah model bahasa yang

dikembangkan oleh Google AI Language pada tahun 2018.[14] Nama "Bidirectional" menekankan kemampuan unik model ini untuk memahami konteks sebuah kata dengan melihat ke arah kiri dan kanan secara bersamaan di semua lapisan arsitektur.[14] Hal ini berbeda secara fundamental dengan model tradisional yang hanya memproses teks secara sekuensial.[14]

2.5.2 Cara Kerja BERT

BERT dilatih menggunakan metode pembelajaran mandiri pada korpus teks yang tidak berlabel (seperti Wikipedia dan BooksCorpus) melalui dua tugas utama [15]:

1. **Masked Language Model (MLM)**: Sekitar 15% dari kata-kata dalam sebuah kalimat disembunyikan menggunakan token ``. Model dilatih untuk memprediksi kata yang hilang berdasarkan konteks sekitarnya.[14] Strategi ini memungkinkan model untuk belajar representasi bidireksional yang dalam.[15]
2. **Next Sentence Prediction (NSP)**: Model dilatih untuk memprediksi apakah kalimat B benar-benar merupakan kalimat yang mengikuti kalimat A. Tugas ini sangat penting untuk memahami hubungan antar kalimat dalam tugas seperti menjawab pertanyaan (*Question Answering*).[15]

2.5.3 Arsitektur BERT

BERT menggunakan arsitektur *encoder-only*.[15] Model ini terdiri dari tumpukan lapisan encoder Transformer yang memungkinkan setiap token input berinteraksi dengan setiap token lainnya tanpa batasan arah.[15] Terdapat dua konfigurasi utama:

- **BERT Base**: 12 lapisan encoder, 110 juta parameter.[15]
- **BERT Large**: 24 lapisan encoder, 340 juta parameter.[15]

Setiap input dimulai dengan token spesial `` yang representasi akhirnya digunakan untuk tugas klasifikasi seluruh kalimat.[15]

2.5.4 Fungsi dan Penggunaan BERT

BERT sangat unggul dalam tugas-tugas *Natural Language Understanding* (NLU), yaitu tugas yang membutuhkan pemahaman makna yang tepat dari teks yang sudah ada.[12] Fungsinya meliputi:

- **Klasifikasi Teks**: Menentukan kategori email (spam/bukan) atau sentimen ulasan (positif/negatif).[22]
- **Named Entity Recognition (NER)**: Mengidentifikasi nama orang, lokasi, atau organisasi dalam teks.[11]
- **Question Answering**: Mencari jawaban spesifik dari sebuah paragraf teks, seperti yang dilakukan oleh sistem pencarian Google.[14]

2.5.5 Contoh Penggunaan BERT dalam Dunia Nyata

Aplikasi paling signifikan dari BERT adalah pada mesin pencari Google Search, di mana ia membantu memahami kueri pencarian yang panjang dan kompleks secara lebih manusiawi.[11] BERT juga digunakan dalam sistem moderasi konten otomatis untuk mendeteksi ujaran kebencian atau disinformasi di platform media sosial dengan tingkat akurasi yang sangat tinggi.[22] Dalam dunia medis, varian BERT yang dilatih khusus (BioBERT) digunakan untuk mengekstraksi informasi dari ribuan jurnal ilmiah guna membantu riset obat-obatan.[42]

BAB III ANALISIS DAN PERBANDINGAN MODEL

3.1 Analisis Kelebihan GPT-4

GPT-4 merepresentasikan lompatan signifikan dalam kemampuan AI generatif dibandingkan versi sebelumnya. Berdasarkan berbagai evaluasi teknis, kelebihan utama GPT-4 meliputi:

1. **Kemampuan Penalaran dan Akurasi Tinggi**: GPT-4 menunjukkan performa level manusia pada berbagai benchmark akademik. Model ini mampu lulus ujian Bar Hukum (simulasi) dengan skor di persentil ke-90, sebuah peningkatan drastis dari GPT-3.5 yang berada di persentil ke-10.[16]
2. **Pemrosesan Multimodal**: Salah satu keunggulan eksklusif GPT-4 adalah kemampuannya memproses input visual. Model dapat "melihat" gambar, memahami grafik, dan memberikan penjelasan deskriptif atau melakukan penalaran berdasarkan elemen visual tersebut.[16]
3. **Kreativitas dan Gaya Bahasa yang Luwes**: GPT-4 sangat mahir dalam menghasilkan teks yang mengalir secara alami, mampu meniru berbagai gaya penulisan, dari formalitas hukum hingga ekspresi kreatif puisi, serta memiliki koherensi jangka panjang yang lebih baik untuk teks hingga 25.000 kata.[33]
4. **Keamanan dan Penyelarasan Etis**: Melalui proses RLHF yang intensif, GPT-4 memiliki kemungkinan 82% lebih rendah untuk menanggapi permintaan konten yang dilarang dan 19% lebih tinggi dalam memberikan informasi faktual dibandingkan pendahulunya.[16]
5. **Kemampuan Multibahasa yang Luas**: GPT-4 melampaui performa model state-of-the-art lainnya dalam 24 dari 26 bahasa yang diuji, termasuk kemampuannya memahami dialek regional dan variasi bahasa lokal yang kompleks.[16]

3.2 Analisis Kekurangan GPT-4

Meskipun sangat kuat, GPT-4 memiliki keterbatasan yang harus diperhatikan dalam konteks akademik dan industri:

1. **Risiko Halusinasi**: Model masih sering menghasilkan informasi yang terdengar meyakinkan tetapi secara faktual salah.[16] Hal ini sangat berbahaya dalam domain medis atau hukum di mana akurasi mutlak diperlukan.[18]
2. **Biaya Komputasi dan Operasional**: Karena skalanya yang masif, GPT-4 memerlukan sumber daya GPU yang sangat besar. Penggunaan melalui API OpenAI melibatkan biaya yang signifikan, menjadikannya kurang efisien untuk tugas-tugas klasifikasi sederhana

dibandingkan model kecil.[19]

3. **Sifat "Black Box" dan Privasi**: Arsitektur internal dan data pelatihan GPT-4 tidak dipublikasikan secara transparan (tertutup), yang menimbulkan kekhawatiran tentang bias yang tertanam serta masalah privasi data saat mengirimkan informasi sensitif ke server eksternal.[27]
4. **Kurangnya Pembelajaran Real-Time**: Pengetahuan GPT-4 bersifat statis hingga tanggal pemutusan data pelatihannya. Model tidak "belajar" dari pengalaman interaksi harian kecuali melalui fine-tuning atau integrasi alat eksternal.[16]
5. **Ketergantungan pada Jaringan Internet**: Sebagai model berbasis cloud besar, GPT-4 memerlukan koneksi internet yang stabil dan memiliki latensi yang lebih tinggi untuk pemrosesan tugas dibandingkan model yang dapat dijalankan secara lokal (on-premise).[45]

3.3 Analisis Kelebihan BERT

BERT tetap menjadi pilihan utama untuk banyak aplikasi NLU karena beberapa keunggulan fundamental:

1. **Pemahaman Konteks Bidireksional yang Dalam**: Karena BERT melihat kalimat dari kedua arah sekaligus, ia sangat mahir dalam membedakan makna kata yang bergantung pada konteks (seperti kata "bisa" yang berarti ular atau sanggup).[12]
2. **Efisiensi Fine-Tuning**: BERT dapat disesuaikan untuk tugas spesifik dengan sangat cepat. Hanya diperlukan satu lapisan tambahan dan waktu pelatihan selama satu hingga beberapa jam pada GPU standar untuk mencapai hasil state-of-the-art pada tugas tertentu.[14]
3. **Open Source dan Transparan**: Kode sumber dan model pra-terlatih BERT tersedia secara bebas di GitHub. Hal ini memungkinkan komunitas untuk melakukan audit, modifikasi, dan menjalankan model secara aman di infrastruktur sendiri tanpa biaya lisensi.[11]
4. **Akurasi Tinggi untuk Tugas Analisis**: BERT secara konsisten mengungguli model lain dalam tugas klasifikasi teks, Named Entity Recognition, dan pemahaman hubungan antar kalimat seperti yang dibuktikan pada benchmark GLUE.[14]
5. **Kebutuhan Sumber Daya yang Terukur**: Dengan parameter yang berkisar antara 110 juta hingga 340 juta, BERT jauh lebih ringan dan cepat untuk proses inferensi dibandingkan GPT-4, menjadikannya ideal untuk aplikasi real-time yang membutuhkan throughput tinggi.[15]

3.4 Analisis Kekurangan BERT

Kelemahan BERT terutama muncul ketika model dihadapkan pada tugas-tugas generatif:

1. **Ketidakmampuan dalam Generasi Teks**: Arsitektur encoder-only BERT tidak dirancang untuk memprediksi kata berikutnya secara berurutan. Akibatnya, BERT tidak dapat digunakan untuk menulis artikel, cerita, atau chatbot percakapan yang kreatif secara

mandiri.[12]

2. **Keterbatasan Panjang Teks (Max Sequence Length)**: BERT standar memiliki batas input maksimal 512 token. Memproses dokumen yang sangat panjang memerlukan strategi tambahan seperti pemotongan teks atau penggunaan varian model lain, yang dapat menyebabkan hilangnya konteks global.[43]
3. **Mismatch Pra-Pelatihan dan Fine-Tuning**: Penggunaan token `` selama pelatihan tidak muncul selama penggunaan aktual di dunia nyata, yang menurut beberapa kritikus dapat sedikit membatasi performa optimal model.[25]
4. **Kebutuhan Data Tanpa Label yang Besar**: Untuk mencapai performa tinggi, BERT memerlukan pra-pelatihan pada korpus teks yang sangat masif, yang memerlukan investasi waktu dan daya komputasi yang besar di tahap awal.[29]
5. **Kurang Fleksibel untuk Tugas Multimodal**: Berbeda dengan GPT-4, BERT murni berbasis teks. Meskipun ada varian untuk gambar (VisualBERT), namun tidak terintegrasi secara seamless dan sekuat kapabilitas multimodal bawaan GPT-4.[17]

3.5 Tabel Perbandingan GPT-4 vs BERT

Berikut adalah tabel sintesis yang membandingkan kedua model secara sistematis:

Dimensi Perbandingan	GPT-4 (Generative Pre-trained Transformer 4)	BERT (Bidirectional Encoder Representations from Transformers)
Tujuan Model	Generasi teks kreatif, penalaran multimodal, dan asisten serbaguna [12]	Pemahaman makna teks (NLU), klasifikasi, dan pencarian informasi [14]
Arsitektur Utama	Transformer Decoder-only (Autoregresif) [17]	Transformer Encoder-only (Deep Bidirectional) [15]
Cara Kerja	Unidireksional: Memprediksi kata berikutnya dari kiri ke kanan [11]	Bidireksional: Memahami kata berdasarkan konteks kiri dan kanan secara simultan [14]
Kelebihan Utama	Multimodal (teks/gambar), kreatif, penalaran kuat, aman (RLHF) [16]	Akurasi semantik tinggi, efisien untuk klasifikasi, open source [11]
Kekurangan Utama	Mahal, risiko halusinasi, black-box, latensi tinggi [16]	Tidak bisa generatif, batas panjang teks 512 token [12]

Penggunaan Utama	Chatbot kreatif, penulisan kode, ringkasan dokumen, analisis visual [12]	Mesin pencari, analisis sentimen, Named Entity Recognition, deteksi spam [11]
Performa Umum	SOTA (State-of-the-art) untuk generatif dan penalaran logis [13]	SOTA untuk tugas klasifikasi dan pemahaman konteks semantik [13]

3.6 Studi Kasus Penggunaan

Aplikasi dunia nyata dari kedua model ini menunjukkan pembagian peran yang jelas dalam ekosistem teknologi:

3.6.1 Studi Kasus BERT: Analisis Sentimen dan Deteksi Disinformasi

Di Indonesia, model BERT (khususnya varian IndoBERT) telah banyak diimplementasikan dalam riset analisis opini publik. Dalam sebuah penelitian klasifikasi sentimen ulasan film menggunakan 5.000 data komentar IMDb, BERT mencapai akurasi rata-rata 96%, jauh melampaui metode tradisional.[46] Studi lain menggunakan IndoBERT untuk mendeteksi berita hoaks politik di media sosial dengan hasil yang menunjukkan bahwa model berbasis bahasa lokal jauh lebih unggul dalam memahami struktur tata bahasa Indonesia yang unik dibandingkan model multibahasa umum.[44] Hal ini membuktikan bahwa BERT adalah pilihan paling logis untuk tugas "analitik" yang membutuhkan presisi tinggi.

3.6.2 Studi Kasus GPT-4: Asisten Profesional dan Aksesibilitas

GPT-4 telah menunjukkan potensi transformatif dalam sektor profesional. Dalam dunia hukum, GPT-4 digunakan untuk meringkas draf kontrak yang sangat panjang dan mengidentifikasi potensi klausul risiko.[18] Dalam sektor kesehatan, meskipun belum menggantikan dokter, GPT-4 digunakan untuk menyusun catatan medis secara otomatis dari dikte suara, yang secara signifikan mengurangi beban administratif tenaga medis.[18] Contoh yang paling menyentuh adalah aplikasi "Be My Eyes," di mana fitur visi GPT-4 memungkinkan pengguna tunanetra untuk mengunggah foto kulkas mereka dan menanyakan, "Apa saja yang bisa saya masak dengan bahan yang tersedia?", di mana AI dapat mengenali label makanan dan memberikan resep secara instan.[33]

BAB IV PENUTUP

4.1 Kesimpulan

Berdasarkan analisis komprehensif yang telah dilakukan, dapat disimpulkan bahwa GPT-4 dan BERT adalah dua pilar teknologi yang memiliki filosofi desain dan fungsi yang saling melengkapi dalam ranah kecerdasan buatan. GPT-4, dengan arsitektur *decoder-only* dan kapabilitas multimodal, adalah model generatif paling mumpuni saat ini yang unggul dalam tugas-tugas

kreatif, penalaran logis, dan interaksi manusia yang luwes.[12] Sebaliknya, BERT, dengan arsitektur *encoder-only* dan pendekatan bidireksional, tetap menjadi standar industri yang tak tertandingi untuk tugas-tugas pemahaman teks yang mendalam, klasifikasi data skala besar, dan pencarian informasi yang efisien.[14]

Perbedaan mendasar dalam cara kerja—di mana GPT-4 memprediksi masa depan secara autoregresif dan BERT menganalisis masa lalu dan masa kini secara simultan—menentukan skenario penggunaan mereka.[11] GPT-4 lebih cocok sebagai asisten cerdas yang mampu menciptakan konten baru, sementara BERT lebih ideal sebagai mesin analitik yang mampu mengekstrak pengetahuan dari data yang sudah ada.[12] Pemilihan antara keduanya harus didasarkan pada pertimbangan akurasi, biaya komputasi, dan kebutuhan akan transparansi data.[5]

4.2 Saran

Untuk masa depan penggunaan dan pengembangan AI, beberapa rekomendasi strategis perlu dipertimbangkan:

1. **Pendekatan Hibrida**: Organisasi disarankan untuk menggabungkan kekuatan kedua model. Sebagai contoh, BERT dapat digunakan untuk menyaring dan mengklasifikasikan ribuan dokumen secara cepat, sementara GPT-4 digunakan untuk menghasilkan ringkasan eksekutif atau jawaban kreatif berdasarkan data yang telah disaring tersebut.[12]
2. **Fokus pada Keamanan dan Etika**: Pengguna harus tetap waspada terhadap potensi halusinasi pada model generatif seperti GPT-4. Implementasi protokol pengawasan manusia (*human-in-the-loop*) sangat krusial, terutama pada aplikasi yang memiliki taruhan tinggi seperti medis, hukum, dan keuangan.[16]
3. **Pengembangan Model Lokal**: Mengingat kesuksesan IndoBERT, sangat disarankan untuk terus mendukung penelitian model bahasa yang dilatih khusus pada dialek dan budaya lokal untuk meningkatkan efektivitas AI dalam konteks nasional.[19]
4. **Adaptasi Terhadap Tren Masa Depan**: Para praktisi harus mulai mempersiapkan diri menghadapi era "Agentic AI" dan model penalaran (*reasoning models*) yang akan datang pada 2025-2026. Di masa depan, AI tidak hanya akan merespons *prompt*, tetapi juga akan mampu memecahkan masalah multi-langkah secara otonom melalui loop kontrol internal yang lebih canggih.[48] Tata kelola dan literasi AI harus menjadi prioritas di lingkungan akademik untuk memastikan teknologi ini digunakan sebagai alat inovasi, bukan pengganti pemikiran kritis manusia.[32]

Works cited

1. Hakikat Epistemologi Artificial Intelligence - Jurnal 3 Universitas Negeri Malang, accessed April 20, 2026, https://journal3.um.ac.id/index.php/ft/article/download/2657/1798
2. Artificial intelligence - Wikipedia, accessed April 20, 2026, https://en.wikipedia.org/wiki/Artificial_intelligence

3. A Brief History of Large Language Models - Dataversity, accessed April 20, 2026, https://www.dataversity.net/articles/a-brief-history-of-large-language-models/
4. History of LLMs: Complete Timeline & Evolution (1950-2026) - Toloka AI, accessed April 20, 2026, https://toloka.ai/blog/history-of-llms/
5. Comparative Evaluation of GPT, BERT, and XLNet: Insights into Their Performance and Applicability in NLP Tasks | Transactions on Computer Science and Intelligent Systems Research, accessed April 20, 2026, https://wepub.org/index.php/TCSISR/article/view/4181
6. The History of Large Language Models: From ELIZA to GPT-5 - Devōt, accessed April 20, 2026, https://devot.team/blog/history-of-large-language-models
7. A Brief History of NLP - WWT, accessed April 20, 2026, https://www.wwt.com/blog/a-brief-history-of-nlp
8. Transformer (deep learning) - Wikipedia, accessed April 20, 2026, https://en.wikipedia.org/wiki/Transformer_(deep_learning)
9. An Overview of Transformer Architecture Using Self-Attention Mechanism:- | by MD AMAN, accessed April 20, 2026, https://medium.com/@amanm15612/an-overview-of-transformer-architecture-using-self-attention-mechanism-e02ad7a6b1a4
10. "A Brief History of NLP: From Rules to Transformers (1960–2020)" | by Ayush Gupta, accessed April 20, 2026, https://medium.com/@ee24m111/a-brief-history-of-nlp-from-rules-to-transformers-1960-2020-a6d1bb15e4f9
11. BERT vs. GPT: What's the Difference? - Coursera, accessed April 20, 2026, https://www.coursera.org/articles/bert-vs-gpt
12. BERT vs GPT: Comparing the Two Most Popular Language Models - InvGate's Blog, accessed April 20, 2026, https://blog.invgate.com/gpt-3-vs-bert
13. EasyChair Preprint - Comparative Analysis of GPT-4 and BERT: Evaluating the Performance and Efficiency of Two Prominent Language Models, accessed April 20, 2026, https://easychair.org/publications/preprint/3mvS/open
14. What Is Google's BERT and Why Does It Matter? | NVIDIA Glossary, accessed April 20, 2026, https://www.nvidia.com/en-us/glossary/bert/
15. BERT (language model) - Wikipedia, accessed April 20, 2026, https://en.wikipedia.org/wiki/BERT_(language_model)
16. GPT-4 Technical Report | OpenAI, accessed April 20, 2026, https://cdn.openai.com/papers/gpt-4.pdf
17. Review of "OpenAI (2023), GPT-4 Technical Report" [4 March 2024], accessed April 20, 2026, https://etcjournal.com/2025/07/29/review-of-openai-2023-gpt%E2%80%914-technical-report-4-march-2024/
18. Beyond ChatGPT: What does GPT-4 add to healthcare? The dawn of a new era - PMC, accessed April 20, 2026, https://pmc.ncbi.nlm.nih.gov/articles/PMC10713213/
19. Effectiveness And Efficiency Of LLM Models Vs Traditional Machine Learning In Sentiment Analysis Of Indonesian Language Product - jurnal unived, accessed April 20, 2026,

https://jurnal.unived.ac.id/index.php/jmcs/article/download/8681/6108
20. Transformer Attention Mechanism in NLP - GeeksforGeeks, accessed April 20, 2026, https://www.geeksforgeeks.org/nlp/transformer-attention-mechanism-in-nlp/
21. Transformer Architecture Explained With Self-Attention Mechanism - Codecademy, accessed April 20, 2026, https://www.codecademy.com/article/transformer-architecture-self-attention-mechanism
22. BERT AI Model: Pahami Cara Kerja dan Bedanya dengan GPT - IDwebhost, accessed April 20, 2026, https://idwebhost.com/blog/bert-ai-model/
23. GPT vs BERT Explained : Transformer Variations & Use Cases Simplified - YouTube, accessed April 20, 2026, https://www.youtube.com/watch?v=AprUD-TSUYE
24. Penggunaan AI Berbasis Large Language Models (LLM) sebagai Media Interaktif dalam Pendidikan Bahasa dan Hukum di Perguruan Tingg, accessed April 20, 2026, https://ojs.stihpada.ac.id/index.php/disiplin/article/download/1560/597/4091
25. A Complete Guide to BERT with Code | Towards Data Science, accessed April 20, 2026, https://towardsdatascience.com/a-complete-guide-to-bert-with-code-9f87602e4a11/
26. Comparative Analysis of GPT-4 and BERT: Evaluating the Performance and Efficiency of Two Prominent Language Models - EasyChair, accessed April 20, 2026, https://easychair.org/publications/preprint/3mvS
27. GPT vs BERT: Which is Better? - Towards Data Science, accessed April 20, 2026, https://towardsdatascience.com/gpt-vs-bert-which-is-better-2f1cf92af21a/
28. Understanding Transformers and Self-Attention | PDF | Machine Learning - Scribd, accessed April 20, 2026, https://www.scribd.com/document/978641921/Transformer-and-Self-Attention-Mechanism
29. BERT: Pre-training of Deep Bidirectional Transformers for Language ..., accessed April 20, 2026, https://research.google/pubs/bert-pre-training-of-deep-bidirectional-transformers-for-language-understanding/
30. Peer review of GPT-4 technical report and systems card - PMC, accessed April 20, 2026, https://pmc.ncbi.nlm.nih.gov/articles/PMC10795998/
31. GPT-4 System Card | OpenAI, accessed April 20, 2026, https://cdn.openai.com/papers/gpt-4-system-card.pdf
32. Regulasi Etika AI di Kampus: Menjaga Integritas Akademik di Era Generative AI - unesa, accessed April 20, 2026, https://s2dikdas.fip.unesa.ac.id/post/regulasi-etika-ai-di-kampus-menjaga-integritas-akademik-di-era-generative-ai
33. GPT-4 Release: Briefing on Model Improvements and Limitations | Morrison Foerster, accessed April 20, 2026, https://www.mofo.com/resources/insights/230315-gpt-4-release-deep-dive-briefing-improvements
34. Future of AI Agents: Top Trends in 2026 - Blue Prism, accessed April 20, 2026,

https://www.blueprism.com/resources/blog/future-ai-agents-trends/
35. AI Definitions: McCarthy and Turing | PDF | Artificial Intelligence - Scribd, accessed April 20, 2026, https://www.scribd.com/document/523018954/What-is-artificial-intelligence
36. Artificial Intelligence. Its Understanding, Goals And History - VOI.id, accessed April 20, 2026, https://voi.id/en/technology/250691
37. Artificial Intelligence - The Swiss Bay, accessed April 20, 2026, https://theswissbay.ch/pdf/Gentoomen%20Library/Artificial%20Intelligence/General/Artificial%20Intelligence%20A%20Modern%20Approach%20-%20Stuart%20J.%20Russell%20%2C%20Peter%20Norvig.pdf
38. Artificial Intelligence A Modern Approach Third Edition - Engineering People Site, accessed April 20, 2026, https://people.engr.tamu.edu/guni/csce625/slides/AI.pdf
39. Inilah Kelebihan GPT-4 Disebut 10 Kali Lebih Canggih dari GPT-3.5 - Planet Gadget, accessed April 20, 2026, https://www.planetgadget.store/blog/kelebihan-gpt-4-dan-perbedaannya-dengan-gpt-3-5.html
40. Kecerdasan Buatan: ChatGPT dalam Pendidikan | PDF - Scribd, accessed April 20, 2026, https://id.scribd.com/document/954258680/MAKALAH-CHATGPT
41. ChatGPT-4 Telah Hadir, Apa Saja Kelebihan GPT-4 atas ChatGPT? - Teknik Elektro ITI, accessed April 20, 2026, https://el.iti.ac.id/chatgpt-4-telah-hadir-apa-saja-kelebihan-gpt-4-atas-chatgpt/
42. What Is the BERT Model and How Does It Work? - Coursera, accessed April 20, 2026, https://www.coursera.org/articles/bert-model
43. PENERAPAN METODE BERT UNTUK ANALISIS SENTIMEN ULASAN PENGGUNA APLIKASI SEGARI DI GOOGLE PLAY STORE, accessed April 20, 2026, https://journal.admi.or.id/index.php/JUIT/article/download/1902/1860/5599
44. Perbandingan Kinerja IndoBERT dan MBERT untuk Deteksi Berita Hoaks Politik dalam Bahasa Indonesia - E-Journal Undiksha, accessed April 20, 2026, https://ejournal.undiksha.ac.id/index.php/JST/article/download/92126/32669/277514
45. Chat GPT adalah: Pengertian, Kelebihan, Kekurangan, dan Cara Menggunakannya, accessed April 20, 2026, https://koinworks.com/blog/chat-gpt-adalah/
46. Pendekatan BERT-based- caused untuk Analisis Sentimen pada Komentar Film, accessed April 20, 2026, https://journal.unpacti.ac.id/index.php/JSCE/article/download/1060/629
47. Menggali Potensi ChatGPT pada Peran Tenaga Kesehatan - e-jurnal, accessed April 20, 2026, https://ejurnal.poltekkes-tanjungpinang.ac.id/index.php/jkstl/article/download/138/84
48. AI Agents in 2025: Expectations vs. Reality - IBM, accessed April 20, 2026, https://www.ibm.com/think/insights/ai-agents-2025-expectations-vs-reality
49. AI Trends 2026: Test-Time Reasoning and the Rise of Reflective Agents - Hugging Face, accessed April 20, 2026, https://huggingface.co/blog/aufklarer/ai-trends-2026-test-time-reasoning-reflect

ive-agen
50. Agentic AI in 2026. From Models to Systems and Why That... | by Nikita S Raj Kapini, accessed April 20, 2026, https://medium.com/@nsr16/agentic-ai-in-2026-661f5b099c2f